

Trabalho Final de Cocada

Flavio Jorge

Julho 2026

1 Introdução

Este trabalho consiste na aplicação do método PCA (Análise de Componentes Principais), estudado durante as aulas do curso, em um contexto prático de visualização e análise das componentes principais de uma matriz composta por valores estatísticos de partidas de tênis.

2 Objetivo

O objetivo é coletar dados públicos e oficiais referentes às estatísticas de jogadores de tênis e avaliar a relevância dessas variáveis em relação à posição dos atletas no ranking mundial. Dessa forma, busca-se investigar se existe uma relação entre o desempenho estatístico dos jogadores e suas respectivas posições no ranking.

Todos os dados utilizados neste trabalho foram coletados a partir da plataforma oficial da ATP (Associação dos Tenistas Profissionais) em 11 de julho de 2026 [1]. As estatísticas disponibilizadas representam a média de desempenho de cada jogador considerando as partidas disputadas nas últimas 52 semanas, correspondendo aproximadamente ao período de um ano.

3 Metodologia

Para realizar a análise, foram utilizados como base três atributos fundamentais do jogo de tênis: saque, devolução e pontos de pressão. Cada um desses atributos é composto por uma série de parâmetros utilizados no cálculo de uma nota final de desempenho. A utilização de métricas estatísticas para avaliação de jogadores tem se mostrado uma abordagem relevante para identificar padrões de desempenho e auxiliar na análise de atletas de tênis [2].

Neste trabalho, não será detalhado o processo de cálculo de cada uma dessas notas, pois serão utilizadas como variáveis de entrada as avaliações já calculadas e disponibilizadas pela ATP. Essa abordagem tem como objetivo simplificar a

análise e reduzir a dimensionalidade do problema, permitindo a aplicação do método PCA de forma mais eficiente.

A coleta e o pré-processamento dos dados foram realizados utilizando scripts desenvolvidos em Python, disponibilizados em um repositório público¹.

Após as etapas de coleta, limpeza e integração dos dados, foi obtida a matriz final utilizada como entrada para o método PCA. Cada linha dessa matriz representa um jogador, enquanto as colunas correspondem às variáveis utilizadas na análise: pontuação no ranking da ATP, avaliação de saque, avaliação de devolução e avaliação em situações de pressão.

3.1 Dataset

A Tabela 1 apresenta uma amostra do conjunto de dados após as etapas de tratamento e organização das informações.

Table 1: Amostra do dataset final utilizado no PCA

Jogador	Pontos ATP	Saque	Devolução	Pressão
J. Sinner	13450	301.2	165.7	261.2
C. Alcaraz	9460	290.6	160.4	244.7
A. Zverev	7190	297.1	142.2	222.9
F. Auger-Aliassime	4390	291.5	133.9	249.6
B. Shelton	4160	299.4	121.9	240.7

3.2 Matriz de Correlação

Antes da aplicação do PCA, os dados foram centralizados e padronizados, garantindo que todas as variáveis apresentassem média zero e escala comparável. Em seguida, foi calculada a matriz de correlação entre as variáveis, permitindo avaliar a relação linear existente entre os atributos considerados.

A matriz de correlação obtida é apresentada a seguir:

$$R = \begin{bmatrix} 1.000 & 0.509 & 0.471 & 0.553 \\ 0.509 & 1.000 & -0.199 & 0.304 \\ 0.471 & -0.199 & 1.000 & 0.402 \\ 0.553 & 0.304 & 0.402 & 1.000 \end{bmatrix}$$

A partir da decomposição da matriz de correlação em autovalores e autovetores, foram determinadas as componentes principais do conjunto de dados. Os autovalores representam a quantidade de variância associada a cada componente e são utilizados para calcular a proporção de informação preservada após a redução dimensional.

¹Código-fonte disponível em: <https://github.com/flavin27/atp-pca>

3.3 Autovalores

Os autovalores obtidos foram:

$$\lambda = \begin{bmatrix} 2.104 \\ 1.205 \\ 0.491 \\ 0.200 \end{bmatrix}$$

A partir dos autovalores obtidos, foi calculada a variância explicada por cada componente principal. Essa métrica representa a proporção da informação original dos dados que é preservada por cada componente após a transformação realizada pelo PCA.

3.4 Variância explicada

A Tabela 2 apresenta a variância explicada individual e acumulada de cada componente principal. Observa-se que as duas primeiras componentes concentram aproximadamente 82,74% da variabilidade total dos dados, indicando que uma representação bidimensional utilizando apenas PC1 e PC2 é capaz de preservar a maior parte das informações presentes no conjunto original.

Table 2: Variância explicada pelas componentes principais

Componente	Variância explicada	Variância acumulada
PC1	52.61%	52.61%
PC2	30.13%	82.74%
PC3	12.27%	95.01%
PC4	4.99%	100.00%

3.5 Componentes Principais

Os pesos associados a cada variável nas componentes principais permitem interpretar a influência de cada atributo na formação das novas dimensões geradas pelo PCA. Valores absolutos maiores indicam uma maior contribuição da variável para a respectiva componente, enquanto o sinal indica a direção dessa relação.

A primeira componente principal (PC1) explica 52,61% da variância total dos dados e apresenta contribuições positivas de todas as variáveis analisadas. Isso indica que essa componente representa uma medida geral de desempenho dos jogadores, combinando informações relacionadas ao ranking, saque, devolução e desempenho em situações de pressão.

A segunda componente principal (PC2), responsável por 30,13% da variância, apresenta uma forte influência negativa da variável ServeRating e uma influência

positiva da variável *ReturnRating*. Dessa forma, essa componente tende a representar uma oposição entre características relacionadas ao desempenho no saque e na devolução.

As demais componentes apresentam menor contribuição para a variância total dos dados. A PC3 explica 12,27% da variância e possui maior influência da variável *PressureRating*, enquanto a PC4 representa apenas 4,99% da variância e apresenta menor relevância para a análise.

Table 3: Pesos das variáveis nas componentes principais

Variável	PC1	PC2	PC3	PC4
ATPPoints	0.6226	-0.0686	-0.4435	0.6411
ServeRating	0.3684	-0.7285	-0.1686	-0.5524
ReturnRating	0.4036	0.6783	-0.3070	-0.5317
PressureRating	0.5601	0.0666	0.8250	0.0339

4 Resultados

4.1 Influência de cada atributo

Ao analisar a influência dos atributos coletados, observa-se que a variável *PressureRating*, que representa o desempenho do jogador em situações de pressão, apresenta maior associação com a pontuação no ranking da ATP quando comparada às métricas relacionadas ao saque e à devolução. Esse resultado sugere que, no conjunto de jogadores analisado, a capacidade de manter um alto nível de desempenho em momentos decisivos possui um papel relevante na diferenciação entre atletas de alto nível.




Figure 1: Mapa de calor da matriz de correlação entre as variáveis analisadas.

4.2 Análise da variância explicada pelas componentes principais

A escolha das componentes principais utilizadas na visualização dos jogadores foi baseada na quantidade de variância explicada por cada componente. Essa métrica indica a proporção da informação original dos dados que é preservada após a transformação realizada pelo PCA.

Como apresentado anteriormente, a primeira componente principal (PC1) explica 52,61% da variância total, enquanto a segunda componente (PC2) representa 30,13%. Juntas, essas duas componentes acumulam 82,74% da variabilidade presente no conjunto de dados, indicando que uma representação bidimensional é capaz de preservar a maior parte das informações relevantes dos atributos analisados.

As componentes seguintes apresentam contribuições significativamente menores, com PC3 explicando 12,27% da variância e PC4 apenas 4,99%. Dessa forma, a análise visual dos jogadores será realizada utilizando exclusivamente as componentes PC1 e PC2, pois elas oferecem uma representação reduzida do problema sem uma perda significativa de informação.

A Figura 2 apresenta a distribuição da variância explicada por cada componente principal.




Figure 2: Variância explicada por cada componente principal.

4.3 Visualização dos jogadores no espaço das componentes principais

Após a aplicação do PCA, os jogadores foram projetados em um espaço bidimensional formado pelas duas primeiras componentes principais. Essa representação permite visualizar as similaridades e diferenças entre os atletas considerando simultaneamente todas as variáveis analisadas: pontuação no ranking da ATP, desempenho no saque, desempenho na devolução e desempenho em situações de pressão.

As componentes PC1 e PC2 foram escolhidas para essa visualização, pois juntas representam 82,74% da variância total dos dados. Dessa forma, a projeção em duas dimensões mantém a maior parte da informação presente no conjunto original, permitindo uma análise visual dos padrões existentes entre os jogadores.

A Figura 3 apresenta a distribuição dos jogadores no espaço formado pelas duas componentes principais. Jogadores posicionados próximos possuem características estatísticas semelhantes considerando os atributos analisados, enquanto maiores distâncias indicam perfis de desempenho mais distintos.




Figure 3: Distribuição dos jogadores no espaço das duas primeiras componentes principais.

5 Conclusão

A aplicação do método PCA permitiu reduzir a dimensionalidade do conjunto de dados estatísticos dos jogadores de tênis, preservando uma grande parte da informação original. A análise das componentes principais mostrou que as duas primeiras componentes representam 82,74% da variância total dos dados, possibilitando uma visualização eficiente dos jogadores em um espaço bidimensional.

Além disso, a análise dos pesos das variáveis e da matriz de correlação indicou que o desempenho em situações de pressão apresenta uma associação relevante com a posição dos jogadores no ranking da ATP, destacando que o desempenho de atletas de alto nível não depende apenas de características técnicas tradicionais, como saque e devolução.

Dessa forma, o PCA se mostrou uma ferramenta adequada para identificar padrões e relações entre diferentes atributos de desempenho, permitindo uma análise mais ampla das características que diferenciam os principais jogadores do circuito profissional.

References

- [1] ATP Tour. *ATP Tour Statistics Leaderboard*. Dados estatísticos de saque, devolução e desempenho sob pressão dos jogadores. 2026. URL: <https://www.atptour.com/en/rankings>

`//www.atptour.com/en/stats/leaderboard?boardType=serve&timeFrame=52week&surface=all&versusRank=all&formerNo1=false`
(visited on 07/11/2026).

- [2] Jiabao Zhang. “A Data-Driven Approach to Tennis Player Performance Prediction and Evaluation”. In: *Highlights in Science, Engineering and Technology* 115 (2024), pp. 338–346. DOI: 10.54097/g6qtv78.